



PYTHON



PYTHON實務操作 爬蟲

開始接觸
PYTHON

作者張勝凱
112 學年



目錄

初衷

接觸PYTHON

- 1.動機
 - 2.能力
 - 3.期望的成果
-
-

- 學習動機及目的
- 簡介PYTHON
- 實務操作-爬蟲


part1 公開資料串接

part2 簡易HTML格式解碼

part3 複雜格式解碼

- 失敗與過程
- 心得與感想

接觸



• 動機

平時做事的好奇心以及對於電腦、排版、科技的興趣都是我想要接觸程式的原因，對於週遭事物總是喜歡多加了解和觀察的慾望，更是接觸程式的主要原因，不論是在課業上或是程式上，我都喜歡一步步找尋線索，找尋解決辦法，得知其中的緣由也會讓我得到很大的成就感，是我學習的動力來源。

• 能力

不論是什麼程式語言，耐心和細心絕對是必要的，除了有程式相關知識以及對於網路資訊的理解外，對於事物的洞察，有條理地整合資料，處理細節都是寫程式時所必備的要素。

• 期望的成果

1. 希望能透過自己實際寫程式整合網路資料
2. 學習程式語法的應用
3. 訓練自己的耐心、觀察力
4. 更加了解資訊工程的運用
5. 結合網路資訊從中學習

認識



• 簡介

Python，屬於國際通用的程式語法，如同耳熟能詳的C語言又或者是 Javascript 是能用來對電腦進行實務操作的程式語言，是許多程式初學者的首選，其原因包括，功能性強、語法簡單、套件多，易於操作和管理等，都讓 Python 語言在近年來大受歡迎以及廣泛的使用。

• 功能與用途

Python 的主要功能多用於資料的分析和操作上，例如爬蟲。同時提供許多方便的物件和模組提供操作者使用，然而 Python 的功能卻不局限於此而已，也可用來製作遊戲，開發網站和軟體等更為複雜的實務操作，例如著名的 Django 和 flask，都是利用 python 開發，在現今用途廣泛。

• 未來發展

隨著科技創新，軟體的開發與應用必是未來發展的一大方向，在人手一機的時代，程式如影隨形，處處都能看見它們的存在，日後能在資訊佔持領域上帶來不小的影響，也加深了對我們的重要性以及學習的必要性。

實務操作PART1- python 公開資料串接

程式碼

```
crawler tandem .py •
crawler tandem .py > ...
1 import urllib.request as req #import urllib.request用來串連線網址
2 import json #import json 用來解碼json格式的資料
3 src="https://data.tapei/api/v1/dataset/296acfa2-5d93-4706-ad58-ea
4 | #台北市內湖科技園區廠商名錄資料(API網址)為json資料格式
5
6 with req.urlopen(src) as response: # 利用with req.urlopen串接資料
7     data=json.load(response)#利用json模組處理json
8
9 clist=data["result"]["results"]#分析出資料所在字典的鍵值
10 with open("data.txt", "w", encoding="utf-8") as file:
11     for company in clist:
12         file.write(company["公司名稱"]+"\n")
13 #最後利用with open寫法 和for迴圈將資料打包成.txt文字檔
```

執行結果

```
crawler tandem .py data.txt X
data.txt
1 浩睿生醫科技有限公司
2 芳紳國際有限公司
3 艾立無限股份有限公司
4 衣綠企業有限公司
5 科盧訊顧問有限公司
6 朝樂股份有限公司
7 核心智慧股份有限公司
8 毅傳媒控股股份有限公司
9 鐵雲人工智慧股份有限公司
10 永京建設股份有限公司
11 維丞國際實業股份有限公司
12 橙楓電子商務股份有限公司
13 廣明建設股份有限公司
14 沁閣投資有限公司
15 研石國際有限公司
16 愛迪福利科技股份有限公司
17 富泰實業股份有限公司
18 昀嘉有限公司
19 佰德管理顧問有限公司
20 茂博網路服務有限公司
21
```

操作

STEP1.

找到想要串接的公開資料，並且找到能提供程式解析的API網址進行解析(以台北市內湖科技廠商名錄為串接資料)

STEP2.

利用python程式中解碼，首先，因api資料為json格式因此利用import json 和 urllib.request進行解析

STEP3.

利用python程式with urlopen進行串接和json格式的處理

STEP4.

找到廠商名單所在的鍵值(JSON格式對PYTHON來說為字典)將鍵值取出便得到廠商名單

STEP5.

最後利用with open語法建立txt檔案，將廠商名錄打包

爬蟲要點:

在這次得實務操作中我學到爬蟲關鍵在於觀察，找到自己所需要的資料，並對其解析。

實務操作PART2- python 簡易HTML格式解碼

程式碼

```
crawler tandem.py • crawler html.py • crawler slenium.py •
crawler html.py > ...
1 import urllib.request as req #import urllib.request用來串連網址
2 url="https://www.ptt.cc/bbs/movie/index9498.html" #ptt電影版含文章標題的html原始碼
3
4 request=req.Request(url,headers={
5     "User-Agent":"Mozilla/5.0 (Windows NT 6.3; Win64; x64) AppleWebKit/537.36 (KHTML
6 })
7 #利用urllib.request中的req.Request方法代入網址(url)和標頭(headers User-Agent)
8 #目的在於模仿正常的使用者請求
9
10 with req.urlopen(request) as response: #對網址發出連線請求
11     data=response.read().decode("utf-8")#將抓取到的網址資訊，利用(utf-8)編碼轉譯
12
13
14 import bs4 #載入beautifulsoup套件幫忙解析html檔案
15 root=bs4.BeautifulSoup(data, "html.parser")#利用beautifulsoup功能解析得到html資料
16 titles=root.find_all("div", class_="title")#利用find找所有標籤"div"和所屬類別"title"
17
18 for title in titles:
19     if title.a!= None:#如果標題包含 a 標籤(沒有被刪除),印出來
20         print(title.a.string)#標題中a標籤內的字串即是文章標題
21 #最後利用for迴圈將簡化後資料列印出來
22
```

執行結果

```
PS C:\Users\user\Desktop\PYTHON> & C:/Users/user/AppData/L
[新聞] 《侏羅紀世界》 彩蛋回顧
[片單] 瞬間安靜的搞笑片段
[問片] 一部電影，拉板凳唱歌
[好雷] 《拜金女王的性愛派對》崩壞三觀就能讓你一夜致富
[好雷] 慾海浮沉尋救贖－《拜金女王的性愛派對》
[好雷] 天怒 La ira de Dios (Netflix 阿根廷片)
[好無雷] 侏羅紀世界 統霸天下
[情報] Chris Hemsworth承認對《雷神2》感到失望
[LIVE] HBO 21:00 止水
[新聞] 睽違11年！鞋貓劍客續集問世 「用掉8條命
[情報] 《子彈列車》台灣特製款海報釋出
[新聞] 全新大規模上映《七龍珠超：超級英雄》劇
[普好雷] 《侏羅紀世界：統霸天下》找回爽度，同時也放棄高度
[討論] 捍衛戰士2得罪大陸市場終將被侏羅紀3超越
Re: [討論] 哪些電影角色竟然是同演員，你會驚訝
[好雷] 侏羅紀世界3
[負雷] 未免太冗長的蜘蛛頭監獄
[討論] 日語版的巴斯光年，聲優好強！
[好雷] 捍衛戰士2 喜歡前半段後半段普普
[問片] 正要出版的小說內容卻被提前洩漏
PS C:\Users\user\Desktop\PYTHON>
```

操作

STEP1.

找到想要串接的網站原始碼，並且找到能提供程式解析且須包含內容的html網址進行解析(以ptt電影版標題為目標)

STEP2.

用python程式import beautifulsoup和urllib.request進行解析

STEP3.

利用urllib.request的功能，發送請求和使用User-Agent給網站，進行授權連線，接著將資料連接、載入、轉譯

STEP4.

利用beautifulsoup的功能，載入html資料，利用beautifulsoup提供的find功能，並且找到標題所屬標籤和屬性(class)

STEP5.

將beautifulsoup找到的資料，利用for迴圈，找到資料所屬的字串(string)即是要找的網站文章標題

爬蟲要點:

在這次得實務操作中我學到運用模組套件的重要，對於程式原始碼的觀察與了解，以及如何模仿一個正常使用者，提供該有的附帶資訊，才能順利連線網站。

實務操作PART3- python 複雜格式解碼-SELENIUM

程式碼

執行結果

```
crawler selenium.py > ...
1 from selenium import webdriver #從selenium中import webdriver(用來連結網站、命令)
2
3 #https://sites.google.com/chromium.org/driver/ 此為chromedriver 程式下載處
4 #chromedriver 是用來執行程式碼的驅動程式(用指令操控網頁)
5
6 PATH="C:/Users/user/Desktop/chromedriver_win32/chromedriver.exe"#chromedriver程式的路徑
7 driver=webdriver.Chrome(PATH) #webdriver選擇瀏覽器及chromedriver路徑放入物件driver
8 driver.get("https://ani.gamer.com.tw/")#利用物件driver功能連結到目標網址(以巴哈姆特動畫區為目標)
9 titles=driver.find_elements_by_class_name("anime-name_for-marquee") #利用find找到標題所屬的class放入變數titles
10 clicker=driver.find_element_by_xpath('//*[@id="blockVideoInSeason"]/div[2]/div/div[31]/span')
11 clicker.click() #找到展開更多的網頁按鈕，要求應用程式點擊，展開剩餘資訊以供抓取
12
13 print("本季新番:!!!!!!!!!!!!!!!!!!!!!!!!!!!!")
14 for title1 in titles: #for迴圈找到每個class裡面的標題訊息
15     if title1.text!=None:
16         print(title1.text)
17
18 #!!!!!!!!!!!!!!!!!!!!!!!!!!!!以下同上程式操作模式找不同區塊的標題
19 titles=driver.find_elements_by_class_name("theme-name")
20 clicker=driver.find_element_by_xpath('//*[@id="blockAnimeNewArrive"]/div[3]/span')
21 clicker.click()
22 print("新上架:!!!!!!!!!!!!!!!!!!!!!!!!!!!!")
23 for title2 in titles:
24     print(title2.text)
25
26 driver.quit()#安全關閉程式
27
```

```
crawler tandem.py data.txt
data.txt
1 浩睿生醫科技有限公司
2 芳紳國際有限公司
3 艾立無限股份有限公司
4 衣綠企業有限公司
5 科盧訊顧問有限公司
6 朝樂股份有限公司
7 核心智慧股份有限公司
8 毅傳媒控股股份有限公司
9 鐵雲人工智慧股份有限公司
10 永京建設股份有限公司
11 維丞國際實業股份有限公司
12 橙楓電子商務股份有限公司
13 廣明建設股份有限公司
14 沁閱投資有限公司
15 研石國際有限公司
16 愛迪福利科技股份有限公司
17 富泰實業股份有限公司
18 昀嘉有限公司
19 佰德管理顧問有限公司
20 茂博網路服務有限公司
21
```

操作

STEP1.

找到目標網址，下載chromdriver外部程式，從selenium中import webdriver(對程式進行控制)，以上完成前置環境作業，接著選擇想使用的瀏覽器，設置好chromdriver的路徑(PATH)，便可開始設計程式抓取資料

STEP2.

利用selenium提供的find方法找到標題所在的element以及所屬的class之後抓出標題名稱的name

STEP3.

由於網站有(更多內容)的按鈕以供使用者取得更多資料，因此可以利用selenium中提供的方法，找到按鈕的路徑(xpath)並且利用點擊(click)方法，讓程式點擊按鈕以便蒐集隱藏的資料

STEP4.

將原先用find功能所找到的資料，利用for迴圈，導出資料的資料列表(list)即是要找的標題名稱

爬蟲要點:

可以多利用第三方套件以及模組的幫忙，在爬蟲過程中會快上許多，也省去很多繁雜的程式碼以及步驟，有了其他資源的幫忙，使爬蟲輕鬆不少

失敗與感恩-PART1

公開資料串接



錯誤程式碼

```
crawler tandem wrong.py > ...
1 import urllib.request as req
2 import json
3 src="https://data.taipei/api/v1/dataset/296acfa2-5d93-4706-ad58-e83cc951863d"
4
5 with req.urlopen(src) as response # 忘了加冒號
6     data=json.load(response)
7
8 clist=data["result"] #沒有將字典拆乾淨
9 with open("data.txt", "w" ) as file: #時常忘記加入utf-8編碼，導致無法轉譯中文
10     for company in clist:
11         file.write(company["公司名稱"]+"\n")
12
```

執行結果

```
PS C:\Users\user\Desktop\PYTHON> & C:/Users/user/AppData/Local/
op/PYTHON/crawler tandem wrong.py"
File "c:\Users\user\Desktop\PYTHON\crawler tandem wrong.py",
  with req.urlopen(src) as response # 忘了加冒號
      ~~~~~
SyntaxError: expected ':'
PS C:\Users\user\Desktop\PYTHON>
```

失敗原因

利用with方法時忘記加上冒號，以及沒有了解資料格式(導致字典未拆除乾淨)，和忘記加入utf-8編碼，導致文字轉譯失敗，無法正確讀取

如何改進

要從小地方處理起，熟悉基本語法操作，專注於觀察自己所要的資料，並且仔細分析資料形式並加以精簡，以及若有文字需要轉譯，記得帶上需要的程式例如現今十分通用的(utf-8編碼)

學習

學習到如何正確串接公開資料，以及注意一些平常可能忽略的小細節，這些都有可能牽一髮動全身，一個小小的錯誤就有可能造成程式無法順利運作

失敗與感恩-PART2

簡易HTML格式解碼



錯誤程式碼

```
crawler html wrong.py > ...
1 import urllib.request as req |
2 url="https://www.ptt.cc/bbs/movie/index9498.html"
3
4
5 with req.urlopen(url) as response:
6     data=response.read().decode("utf-8")
7     #在進行連線時忘記帶上User-Agent導致連線失敗
8
9 import bs4
10 root=bs4.BeautifulSoup(data, "html.parser")
11 titles=root.find_all("div", class_="title")
12
13 for title in titles:
14     if title.a != None:
15         print(title.a.string)
16
```

執行結果

```
File "C:\Users\user\AppData\Local\Programs\Python\Python38\python.exe" line 1
return opener.open(url, data, timeout)
File "C:\Users\user\AppData\Local\Programs\Python\Python38\python.exe" line 2
response = meth(req, response)
File "C:\Users\user\AppData\Local\Programs\Python\Python38\python.exe" line 3
response = self.parent.error(
File "C:\Users\user\AppData\Local\Programs\Python\Python38\python.exe" line 4
return self._call_chain(*args)
File "C:\Users\user\AppData\Local\Programs\Python\Python38\python.exe" line 5
result = func(*args)
File "C:\Users\user\AppData\Local\Programs\Python\Python38\python.exe" line 6
raise HTTPError(req.full_url, code, msg, hdrs, fp)
urllib.error.HTTPError: HTTP Error 403: Forbidden
PS C:\Users\user\Desktop\PYTHON> [ ]
```

失敗原因

在連線網址時，忘記將User-Agent資料帶入，導致聚網站拒絕給予全線進入，認為這是不可信任的連線請求

如何改進

在進行爬蟲之前先仔細觀察網站的規律，或是重要的資訊，像是User-Agent和cookies這一類關於網站存取進入方面的資料都要特別注意，以免造成錯誤

學習

學習到原來網站在存取進入時會有個User-Agent這就像是一張許可證，供網站進行識別，要是沒有這張識別證(User-Agent)，便會被網站拒絕存取進入，認為這是有危險或來源不明的請求，因此進行外部連線時要特別注意這一點，同時我也學習到觀察網站架構的技能和重要性

失敗與感恩-PART3

複雜格式解碼

SELENIUM



錯誤程式碼

```
crawler selenium wrong.py > ...
1 from selenium import webdriver
2 |
3 driver=webdriver.Chrome #chromdriver程式的路徑(PATH)忘記放導致根本無法啟動應用程式
4 driver.get("https://ani.gamer.com.tw/")
5 titles=driver.find_elements_by_class_name("anime-name_for-marquee")
6 #沒有程式路徑導致driver呈現無法使用狀態
7 print("本季新番:↓↓↓↓↓↓↓↓↓↓↓↓↓↓↓↓↓↓↓↓")
8 for title1 in titles:
9     if title1.text!=None:
10         print(title1.text)
11
12
13 titles=driver.find_elements_by_class_name("theme-name")
14 clicker=driver.find_element_by_xpath('//*[@id="blockAnimeNewArrive"]/div[3]/span')
15 clicker.click()
16 print("新上架:↓↓↓↓↓↓↓↓↓↓↓↓↓↓↓↓↓↓↓↓")
17 for title2 in titles:
18     print(title2.text)
19
20 #忘了安全關閉程式
```

執行結果

```
PS C:\Users\user\Desktop\PYTHON> & C:/Users/user/AppData/Local/Programs/Python/Python38-64/python crawler selenium wrong.py
Traceback (most recent call last):
  File "c:\Users\user\Desktop\PYTHON\crawler selenium wrong.py", line 4, in <module>
    driver.get("https://ani.gamer.com.tw/")
TypeError: WebDriver.get() missing 1 required positional argument: 'url'
PS C:\Users\user\Desktop\PYTHON> |
```

如何改進

在執行程式前，**需要先做好預前先準備**，要熟悉自己所使用的工具，包括使用方式、以及如何正確歸納和管理自己所運用的套件工具或是檔案


失敗原因

在使用**chromdriver**應用程式時，忘記設定路徑，導致電腦無法找到並開啓執行程式，此外也**未將程式安全關閉**，這可能造成程式的問題

學習

學習到如何正確使用**chromdriver**，以及第三方管理套件**selenium**的使用，我也學習到，**其實程式有許多的變化**，時常都能殊途同歸，解決問題不一定只有一種方法，選擇適合自己，有效率，能解決問題的都是好方法

心得與反思



心得

此次的學習成果不但讓我更加認識python這套程式語言，也看見自己許多的不足，從最基本的公開串接資料到進階一點的簡易html解碼，再到運用程式和套件工具的幫忙完成資料擷取，每一項實作都讓我收穫滿滿，同時我也體會到自己在組織與統整這方面的興趣。而不論是程式運用上或是心態的方面。在程式運作上我學到程式語言的寫法以及操作過程需要注意的事項，在心態方面上我則是學到耐心，和仔細觀察，和專注的重要，一刻分神都有可能造成程式出錯或是進行不順，雖然過程艱辛，但我把這項挑戰當作自我磨練，我也能從程式中找到無限的可能，以及對於成功操作程式的喜悅和成就感，這些都是我無法用言語表達，唯有自己實踐才能得到的可貴收穫。

反思

藉由操作程式，首先使我看見自己在耐心方面的不足，藉由寫程式來磨練自己的耐心和穩定讓我學到許多，其次是細心程度，寫程式可說是一格環節出錯都不允許，需要絕對的細心，否則容易造成錯誤，在學寫程式的過程，雖然剛開始常常失敗，但隨著不斷的練習，一步步訓練出自己的細心，後面的程式操作也有越做越順的成就感，最後是解決問題的能力，我學會如何利用手邊有的資源，或是透過搜尋網路、書本來找尋資源，找到解決方法，學寫程式也使我有更多面向的思考，學會變通，從不同角度切入問題，發揮自己的想像，不怕失敗，盡可能嘗試，找到解決方法的精神，都是我學寫程式這段時間所體會和學習到的。